Cuantificación de la incertidumbre de las predicciones de modelos de aprendizaje automático en problemas de estimación del perfil biológico

Autor
David González Durán

Director
Pablo Mesejo Santiago

Mentor
Javier Venema Rodríguez

Asignatura
Proyecto de Fin de Grado de Ingeniería Informática (2024-2025)

Convocatoria
Extraordinaria de Septiembre

UNIVERSIDAD DE GRANADA

ETSIIT
Escuela Técnica Superior de Ingenierías Informática y de Telecomunicación

Índice

1. Introducción
2. Estado del arte
3. Materiales y métodos
4. Experimentos
5. Conclusiones

Descripción del problema

Paradigma dominante: Predicción puntual

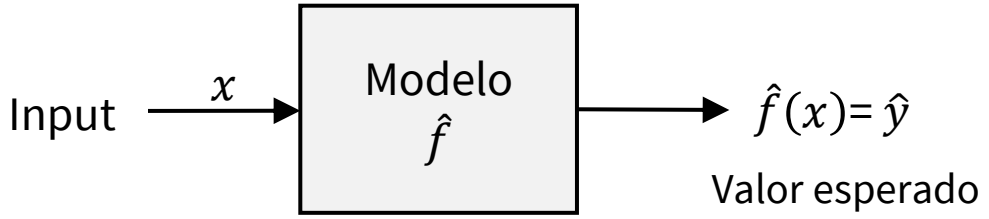

Alternativa: Predicción interválica

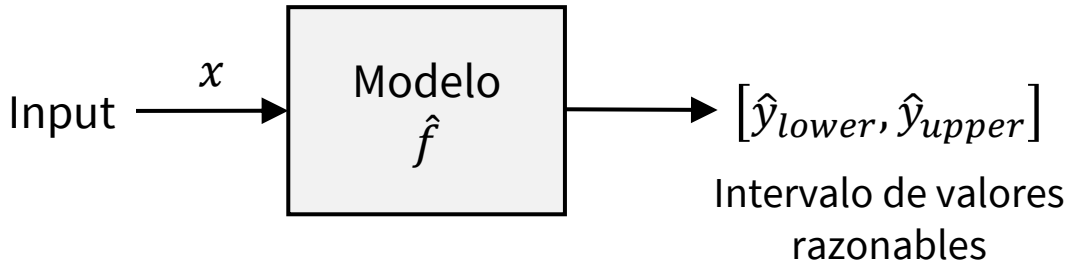

Fenómeno subyacente

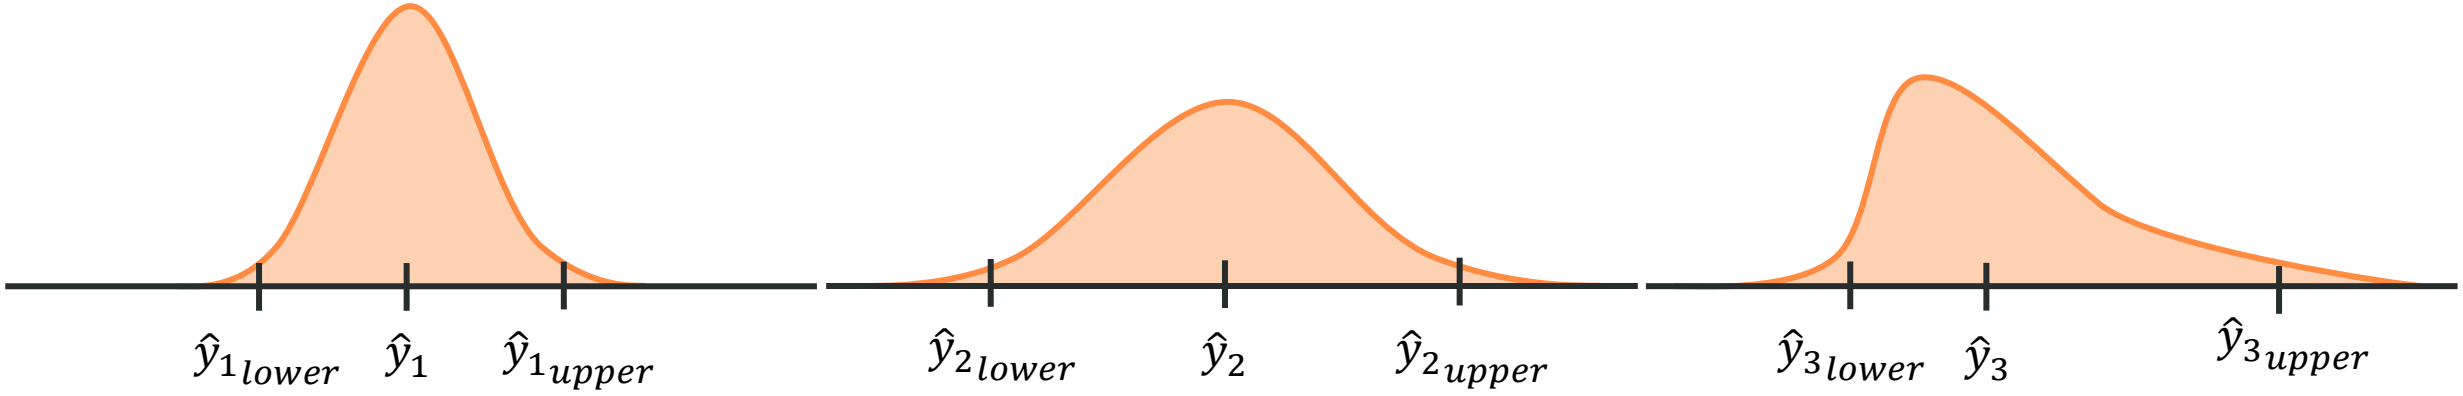

Contexto del problema (I)

▶ Antropología Forense

Técnicas de la antropología física para resolver cuestiones **médico-legales**.

Perfil Biológico

- **Sexo**
- **Edad**
- **Estatura**
- **Ascendencia**

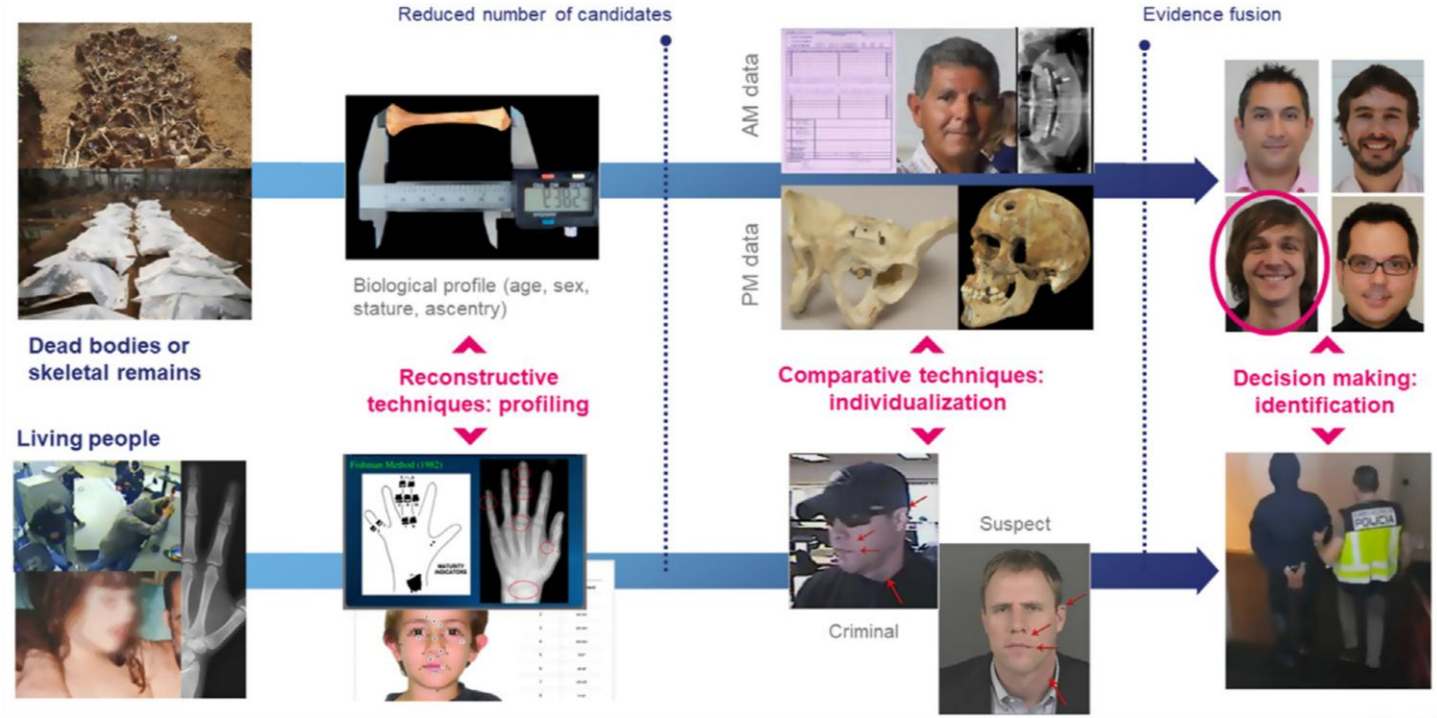

Identificación forense basada en el esqueleto humano [1].

[1] Mesejo, P., Martos, R., Ibáñez, Ó., Novo, J., & Ortega, M. (2020). A survey on artificial intelligence techniques for biomedical image analysis in skeleton-based forensic human identification. *Applied Sciences*, *10*(14), 4703.

Contexto del problema (I)

Antropología Forense

Técnicas de la antropología física para resolver cuestiones **médico-legales**.

▶ Perfil Biológico

- **Sexo**
- **Edad**
- **Estatura**
- **Ascendencia**

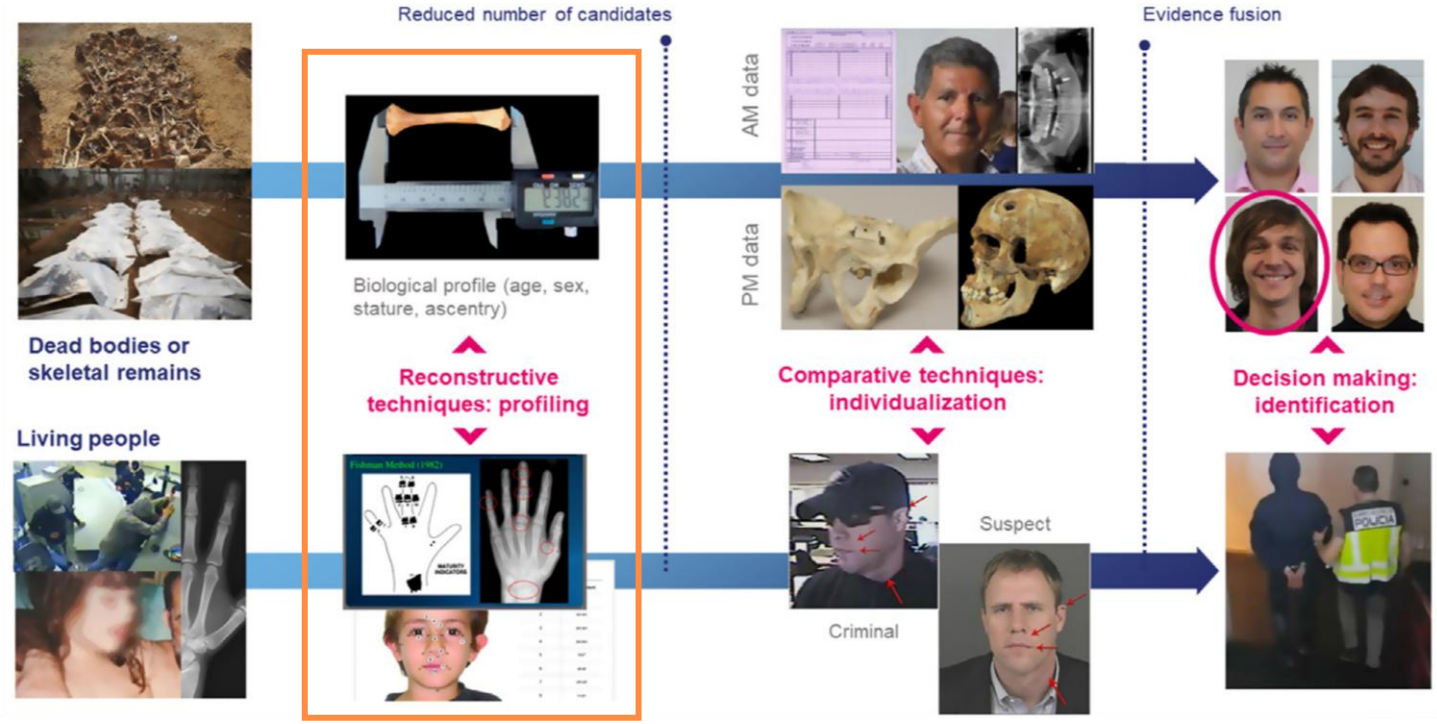

Identificación forense basada en el esqueleto humano [1].

[1] Mesejo, P., Martos, R., Ibáñez, Ó., Novo, J., & Ortega, M. (2020). A survey on artificial intelligence techniques for biomedical image analysis in skeleton-based forensic human identification. *Applied Sciences*, *10*(14), 4703.

Contexto del problema (II)

- **Uso de técnicas de IA y *machine learning*** → Estandariza y aumenta la objetividad en la estimación del perfil biológico

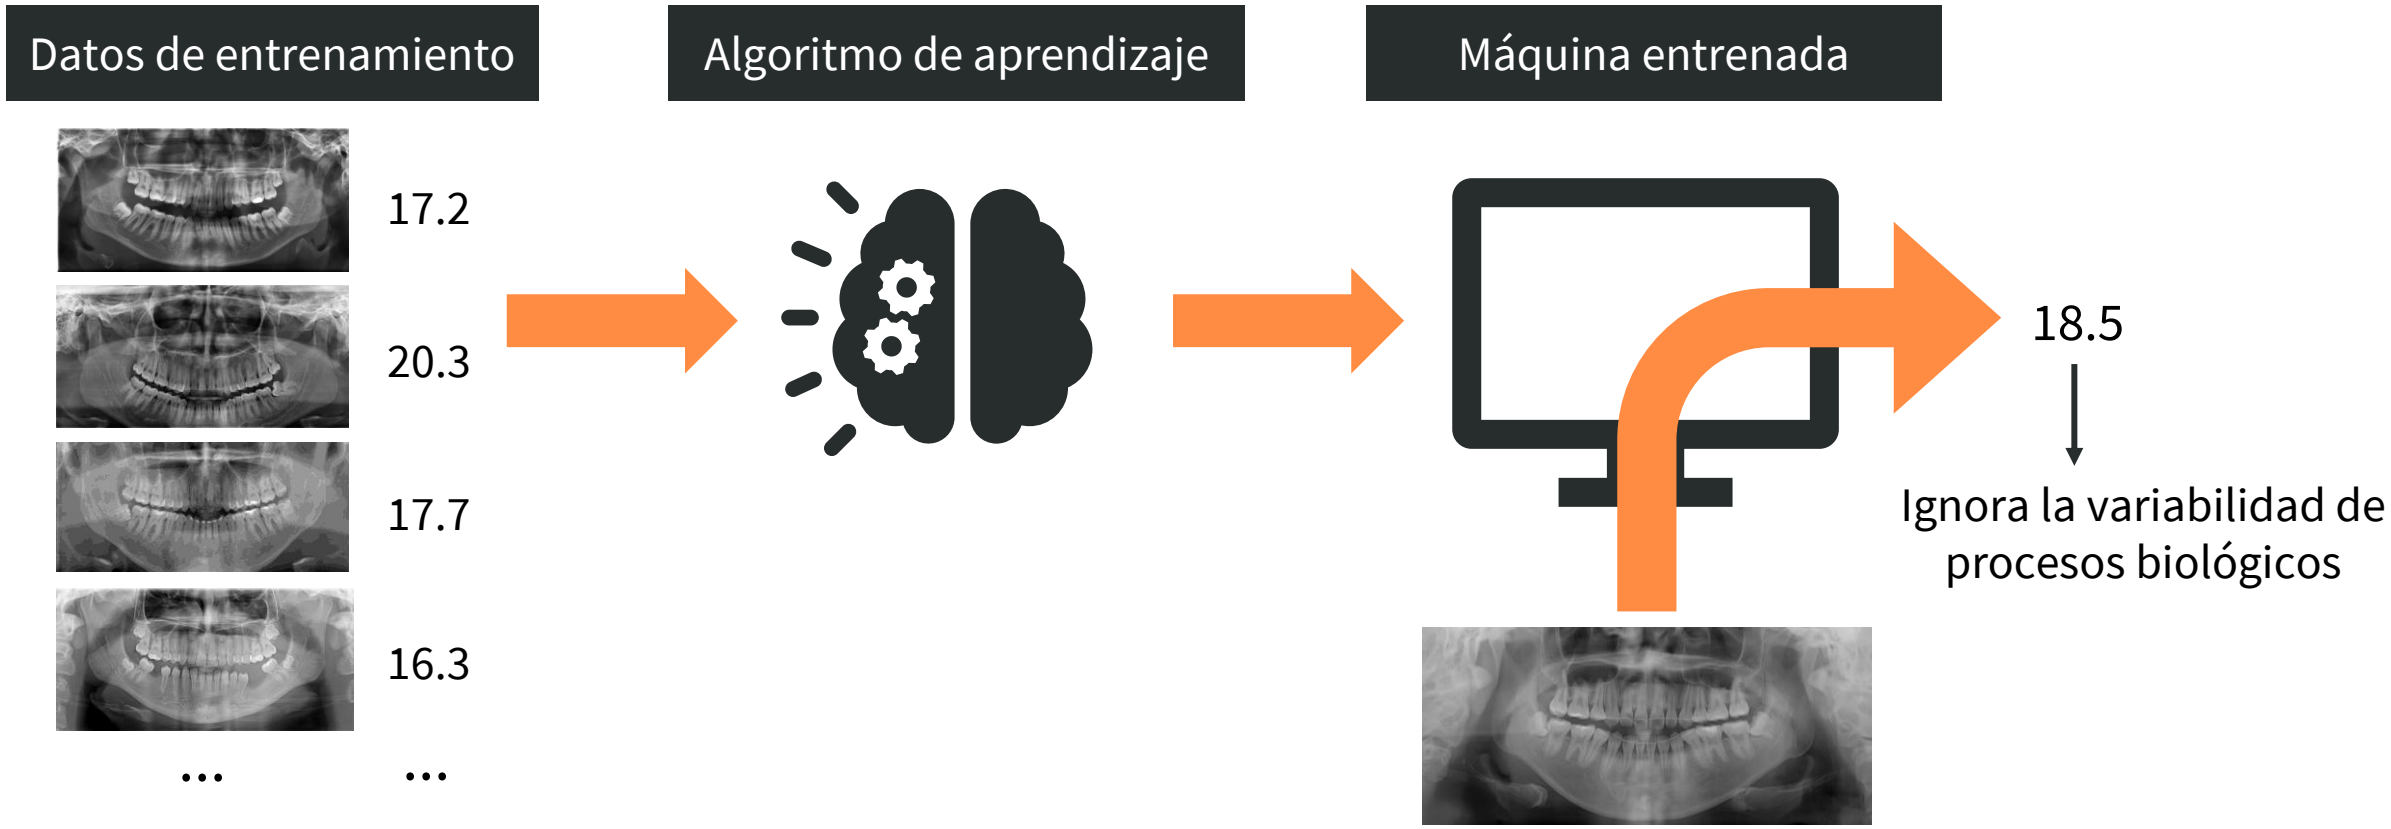

*

Predicción conformal (I)

Marco teórico para generar intervalos de predicción con garantías estadísticas de cobertura para un nivel de confianza deseado.

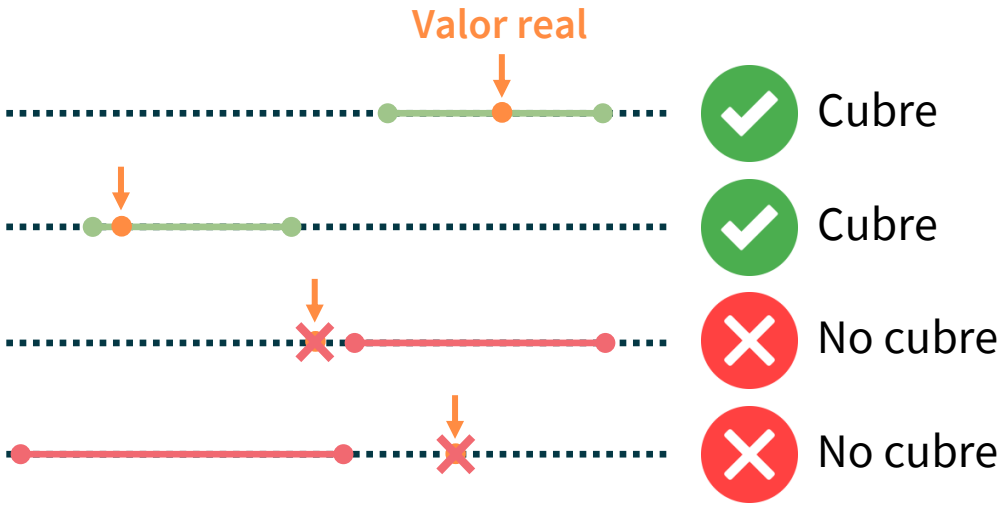

90 % de confianza

garantiza estadísticamente

90 % de los intervalos cubren el valor real

- **Independiente de la distribución** de datos. Solo asume **intercambiabilidad** entre los datos.
- Independiente del modelo (***model-agnostic***).
- **Calibración:** Nuevo paso para la preparación del modelo, justo tras el entrenamiento.
- Requiere un conjunto de **datos de calibración representativo**, para que la cobertura sea efectiva.

Predicción conformal (II)

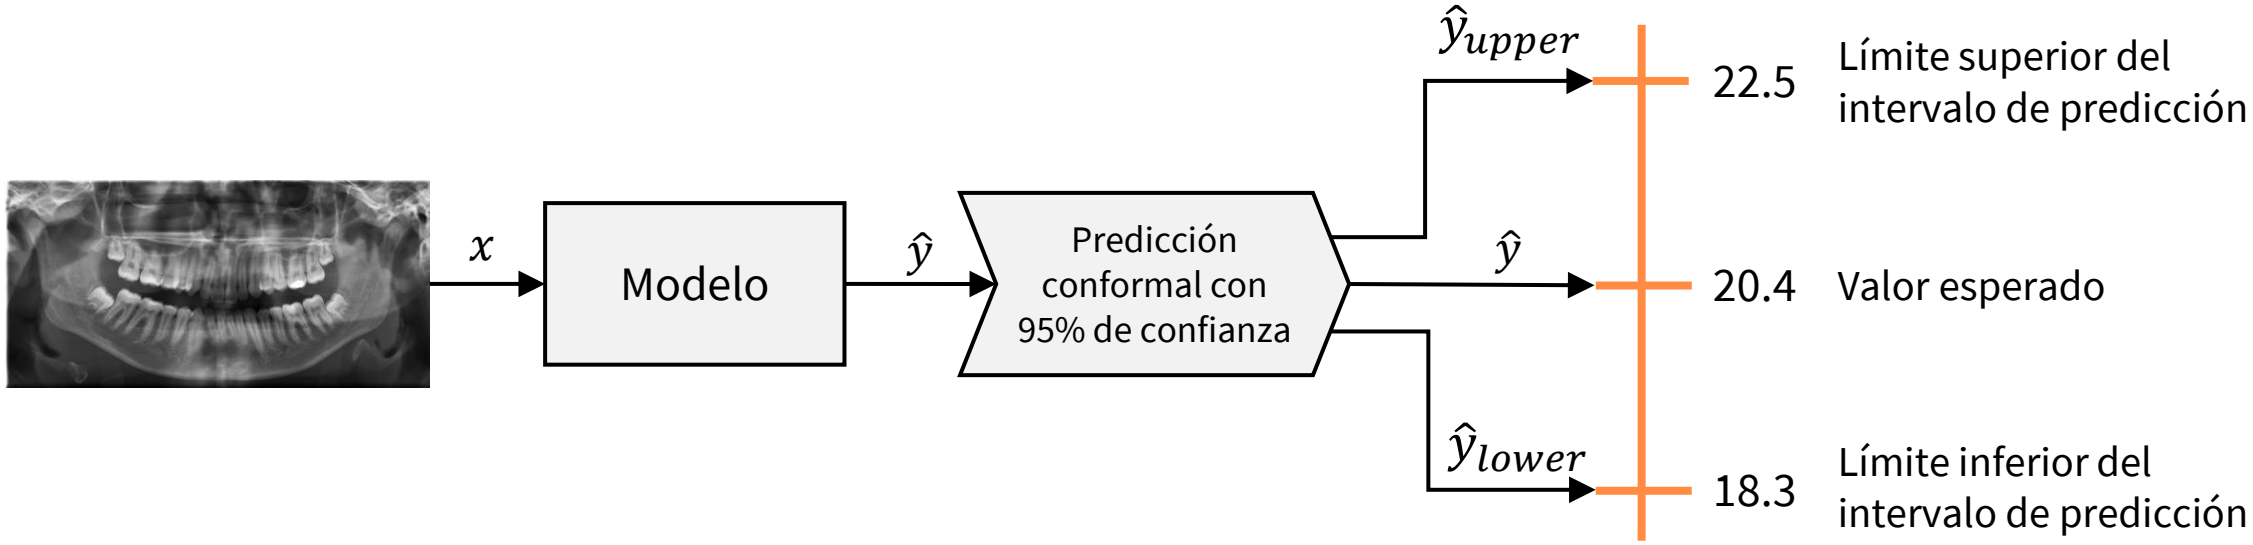

Objetivos

1. **Mostrar la importancia de la cuantificación de incertidumbre** frente al análisis del error en predicciones puntuales

2. **Aplicar métodos de predicción puntual e interválica** a un contexto práctico como la estimación de edad

3. **Comparar y discutir resultados**

Cuantificación de incertidumbre en la estimación de edad manual

Intervalos de edad para la evaluación de indicadores cubren el 95% de los casos

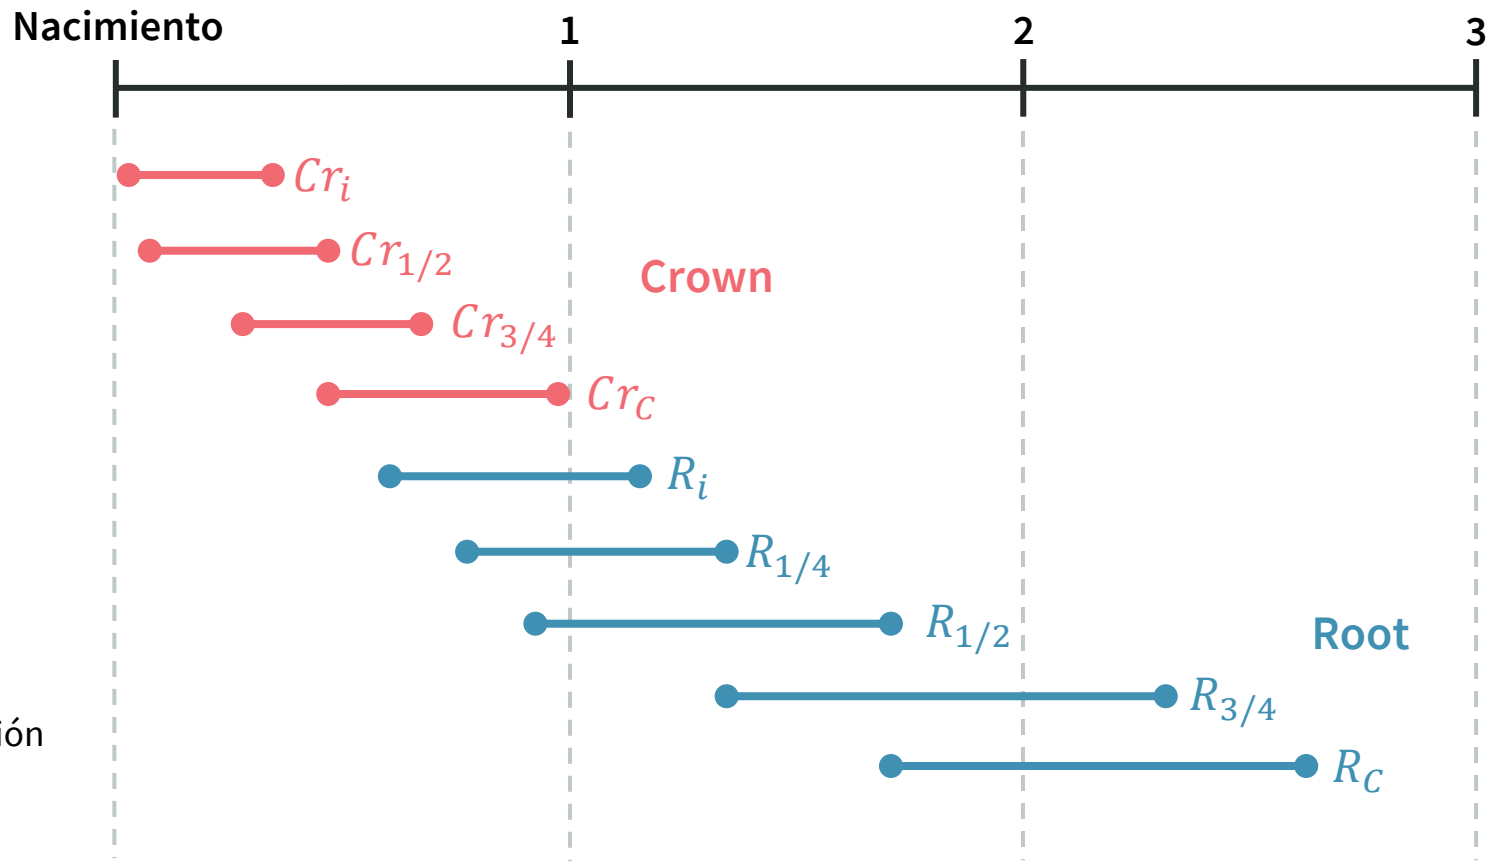

Extracto de cronograma de formación dental para el sexo femenino. Recuperado de [1].

[1] Byers, S. N., & Juarez, C. A. (2023). *Introduction to forensic anthropology*. Routledge.

Cuantificación de incertidumbre en la estimación de edad mediante *machine learning*

Métricas más empleadas:

- **Media ± Desviación estándar**
- **Histograma del error**

Diferenciado por sexo

	cnn-2d-bones-carpal	**cnn-2d-hand**
	(mean ± std [years])	**(mean ± std [years])**
	error histogram [years] (|-3|-2|-1|0|+1|+2|+3|)	**error histogram [years] (|-3|-2|-1|0|+1|+2|+3|)**
Male	**0.49 ± 0.60** |1|13|66|238|92|8|0|	**0.58 ± 0.64** |2|14|97|207|86|10|2|
Female	**0.66 ± 0.61** |0|7|80|174|132|24|0|	**0.89 ± 0.75** |2|41|108|135|95|29|7|
All	**0.57 ± 0.61** |1|20|146|412|224|32|0|	**0.73 ± 0.72** |4|55|205|342|181|39|9|

Fragmento del estudio del error en los métodos 2D propuestos en [1]

[1] Štern, D., Payer, C., & Urschler, M. (2019). Automated age estimation from MRI volumes of the hand. Medical image analysis, 58, 101538.

Conjunto de datos (I)

- 10 739 ejemplos

Ortopantomografías (OPT)

Edad cronológica	Sexo	OPT
25.32	M	ID1
19.46	F	ID2
23.71	M	ID3
...	...	...

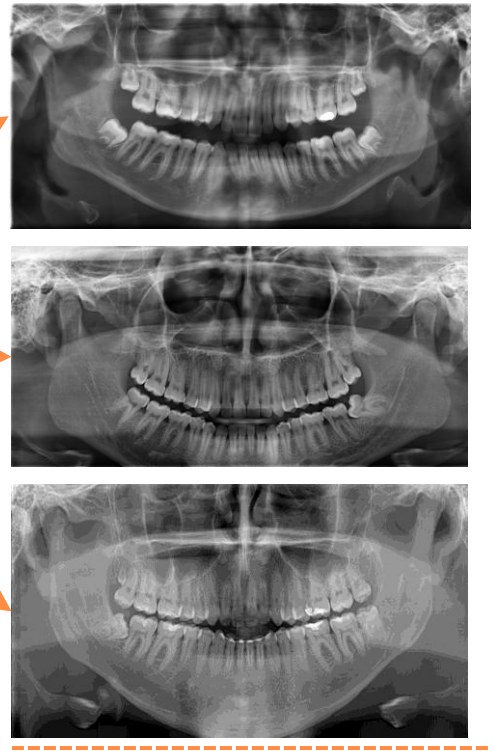

Conjunto de datos (II)

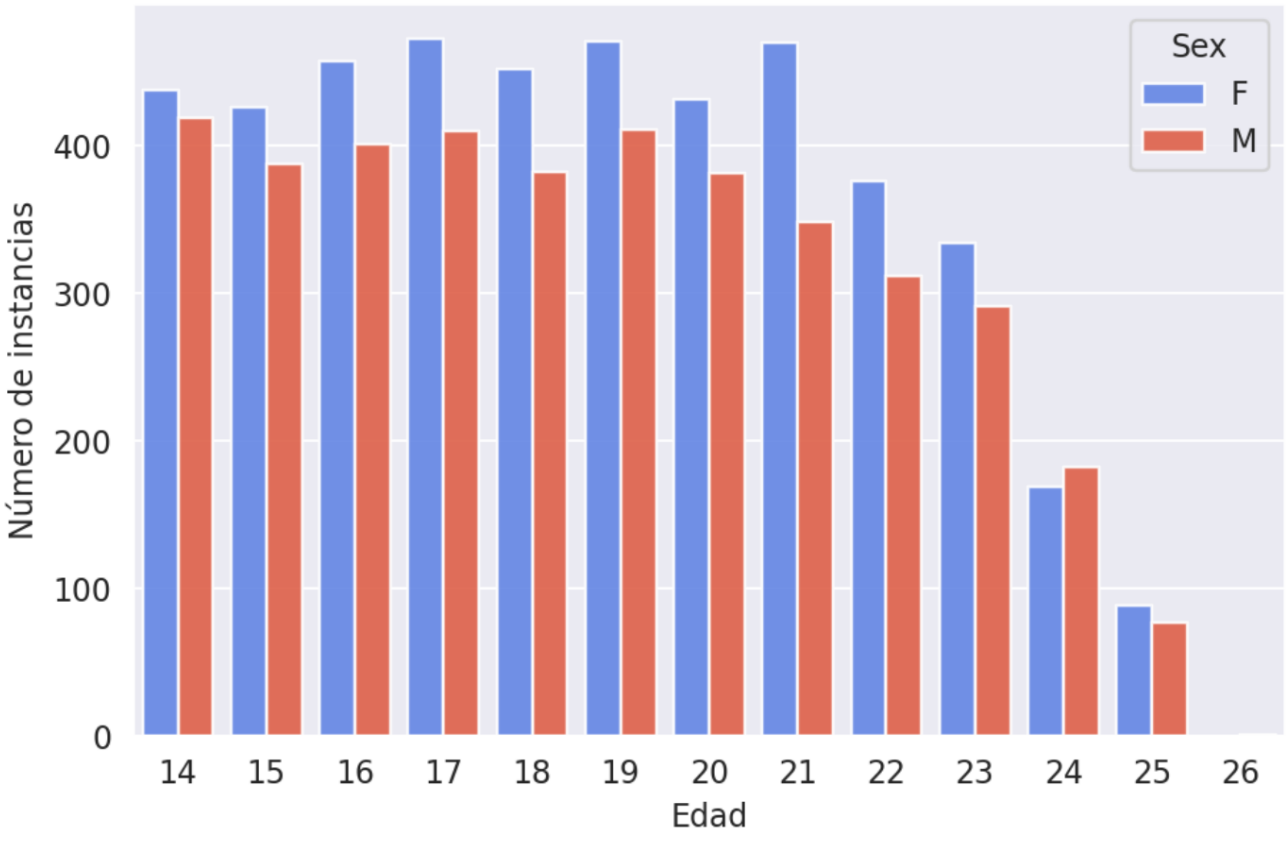

- Edades comprendidas entre 14 y 25 años
- Desbalanceo de datos por edad: disminución de ejemplos a partir de los 22/23 años
- Desbalanceo moderado de datos por sexo

Métodos para predicción interválica (I)

Inductive Conformal Prediction (ICP)

Conjunto de calibración

X	Y
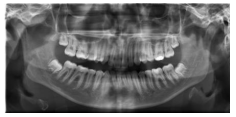	25.3
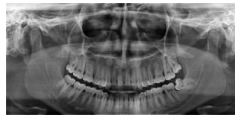	19.5
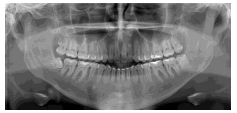	23.7
...	...

$\{x_i\}_1^n$ → Modelo $\hat{f}$ → $\{\hat{y}_i\}_1^n$

Error absoluto $|y_i - \hat{y}_i|$

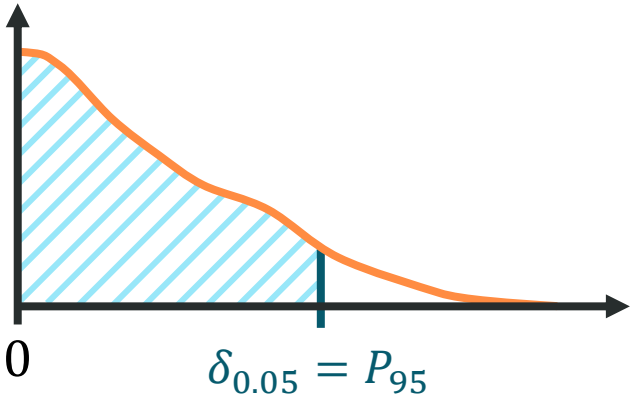

- Tiene **garantías de cobertura**
- Intervalo **simétrico** y de **tamaño fijo**
- **Independiente del modelo**

Nuevo

x_{n+1} → Modelo $\hat{f}$ → $\hat{y}_{n+1}$ → ICP con 95% de confianza

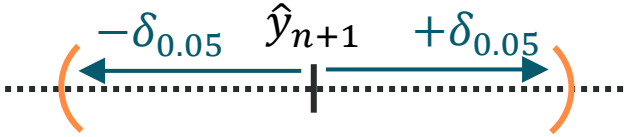

$[\hat{y}_{n+1} - \delta_{0.05}, \hat{y}_{n+1} + \delta_{0.05}]$

$\hat{y}_{n+1}$

Métodos para predicción interválica (II)

Regresión Cuantílica (Quantile Regression, QR)

Nuevo

x

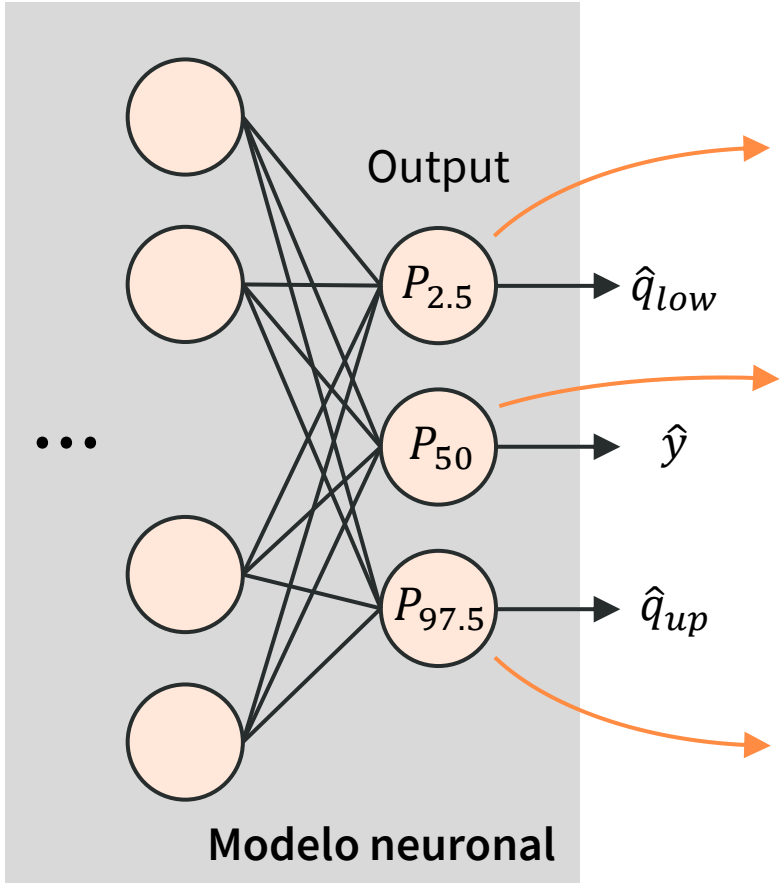

- **No** tiene **garantías de cobertura**
- **Dependiente del modelo**
- Intervalo **asimétrico** y de **tamaño variable**

Función de pérdida

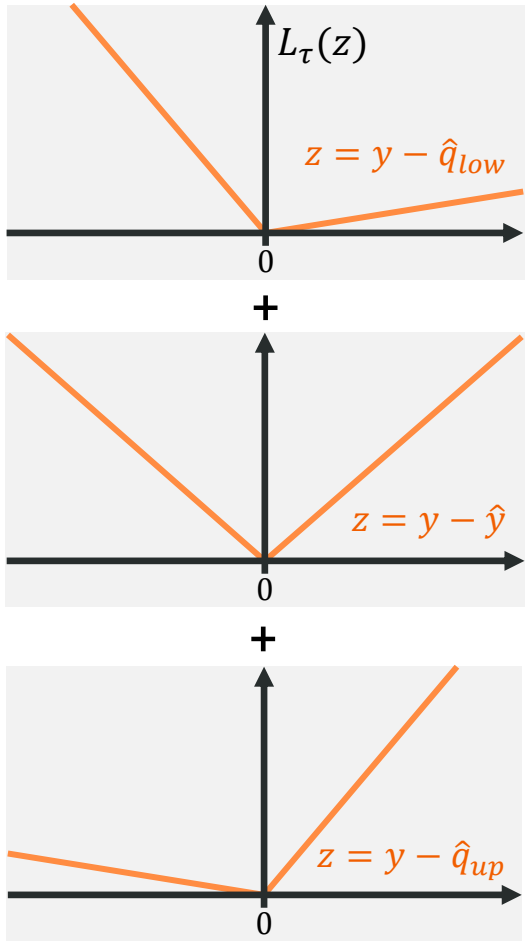

Penaliza más errores negativos

Penaliza igual errores positivos y negativos

Penaliza más errores positivos

*

Métodos para predicción interválica (III)

Conformalized Quantile Regression (CQR)

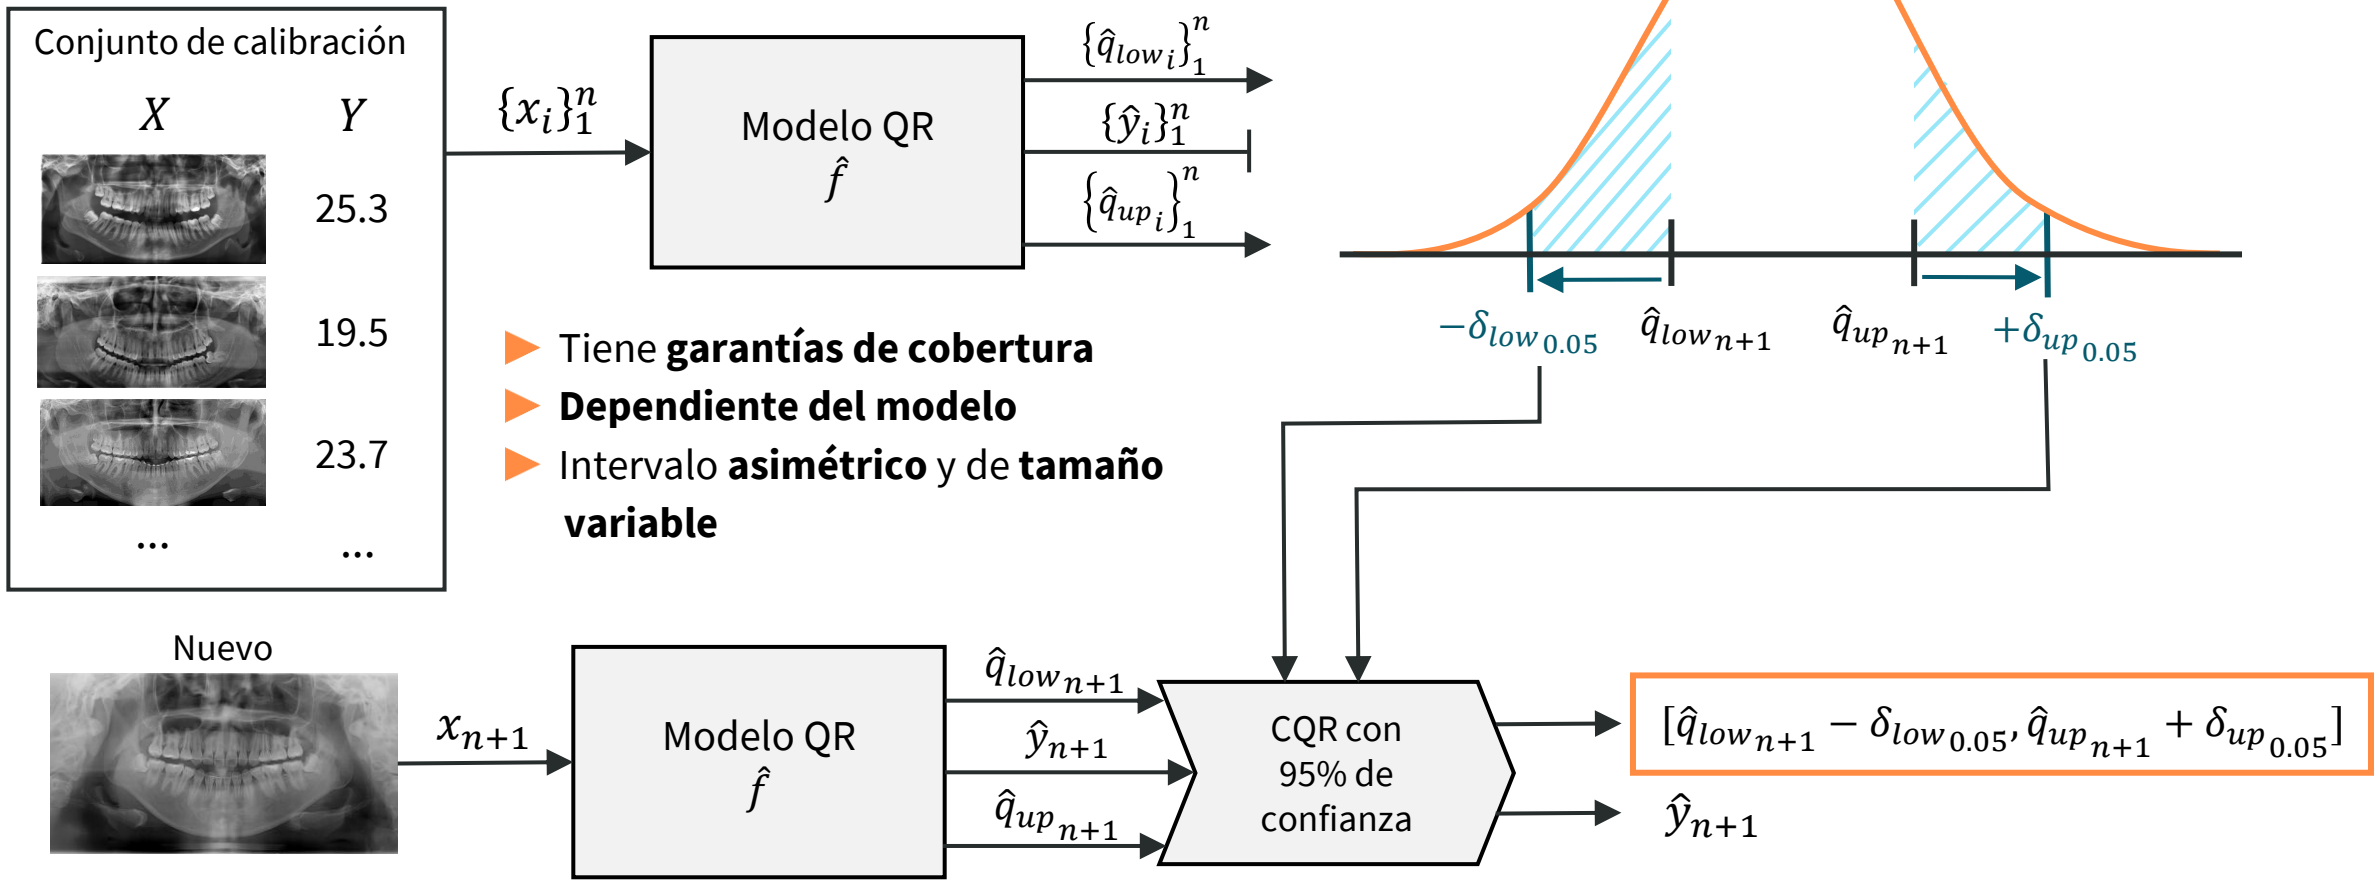

- Tiene **garantías de cobertura**
- **Dependiente del modelo**
- Intervalo **asimétrico** y de **tamaño variable**

Protocolo de validación experimental

Para métodos no conformales:

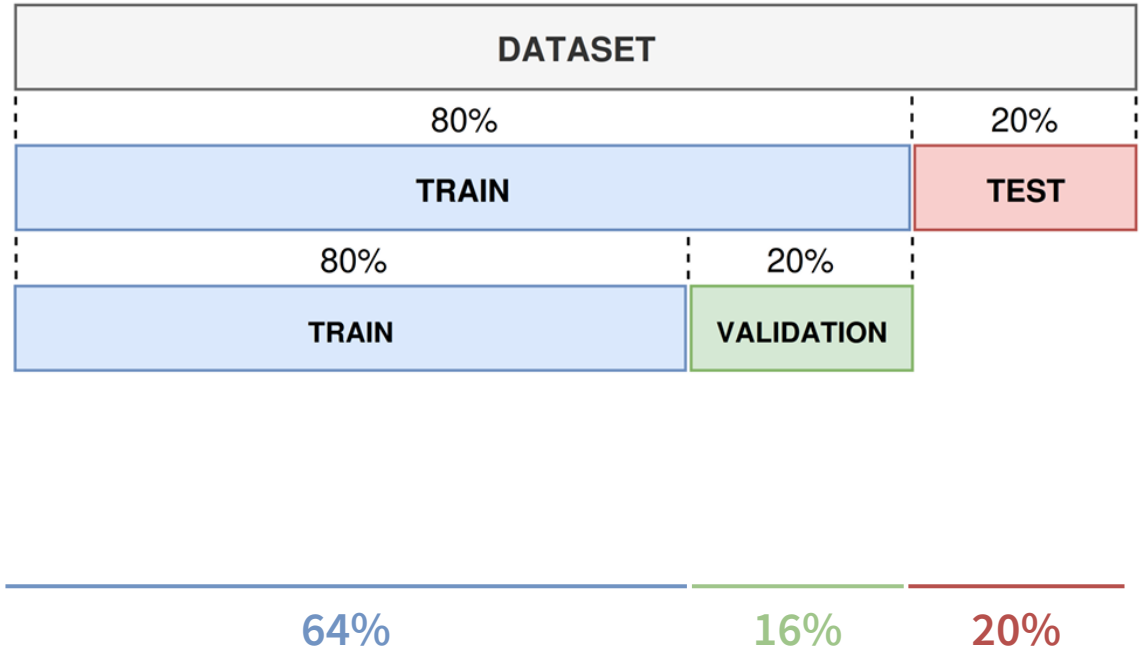

Para métodos conformales:

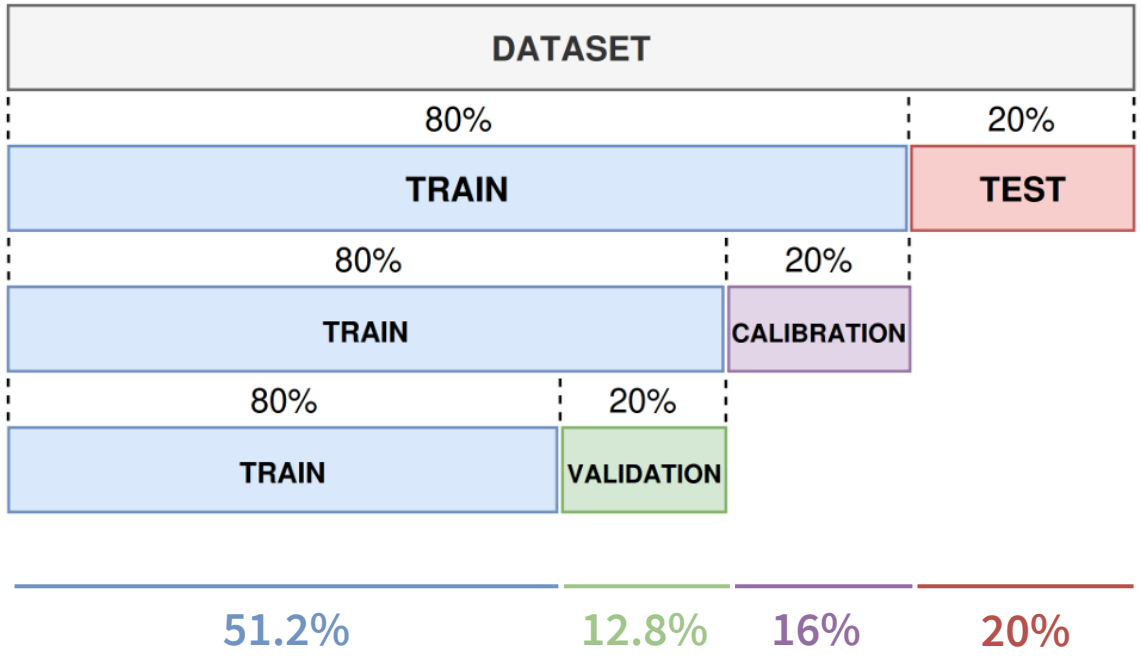

Métricas

1 Cobertura empírica

Proporción de intervalos de predicción generados que contienen el valor real.

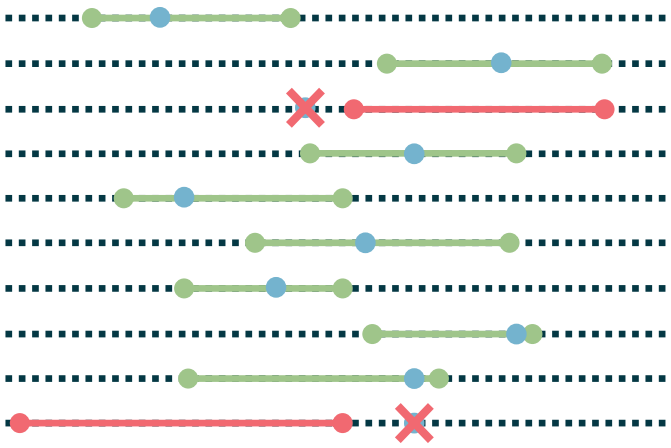

2 Amplitud media del intervalo

Ancho promedio de los intervalos de predicción generados.

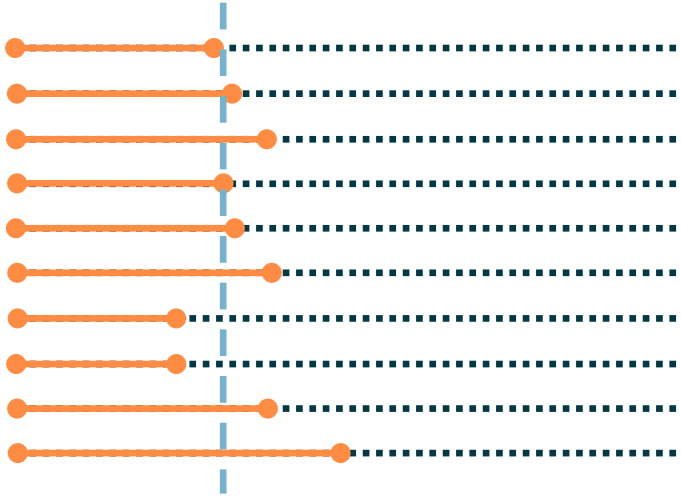

Se pueden medir sobre la población total o subpoblaciones

Esquema de experimentación

1. Método base	2. Método ICP	3. Método QR	4. Método CQR
Predicción puntual ± 2 Error absoluto medio	95% de confianza	95% de confianza	95% de confianza

Backbone: ResNeXt50

10 ejecuciones por cada método

Métricas obtenidas sobre test

Resumen comparativo de los métodos

Métodos	base	ICP	QR	CQR
Garantías de cobertura	✗	✓	✗	✓
Requiere calibración	✗	✓	✗	✓
Intervalos adaptativos (tamaño variable)	✗	✗	✓	✓
Model-agnostic	✓	✓	✗	✗

Resultados (I)

Métrica de predicción puntual

- Los métodos conformales presentan un empeoramiento mínimo de las métricas.

Ejecución	Error Absoluto Medio			
	base	ICP	QR	CQR
Ejecución 1	1.17	1.20	1.17	1.18
Ejecución 2	1.15	1.18	1.17	1.20
Ejecución 3	1.17	1.21	1.17	1.17
Ejecución 4	1.16	1.20	1.14	1.17
Ejecución 5	1.16	1.21	1.16	1.18
Ejecución 6	1.17	1.20	1.16	1.18
Ejecución 7	1.16	1.20	1.18	1.19
Ejecución 8	1.18	1.20	1.17	1.20
Ejecución 9	1.18	1.19	1.17	1.17
Ejecución 10	1.15	1.20	1.15	1.19
Media	**1.16** <	1.20	**1.16** <	1.18

Resultados (II)

Métricas de regresión interválica

- Los métodos conformales logran cobertura del 95%.
- CQR presenta menor amplitud media del intervalo que ICP.

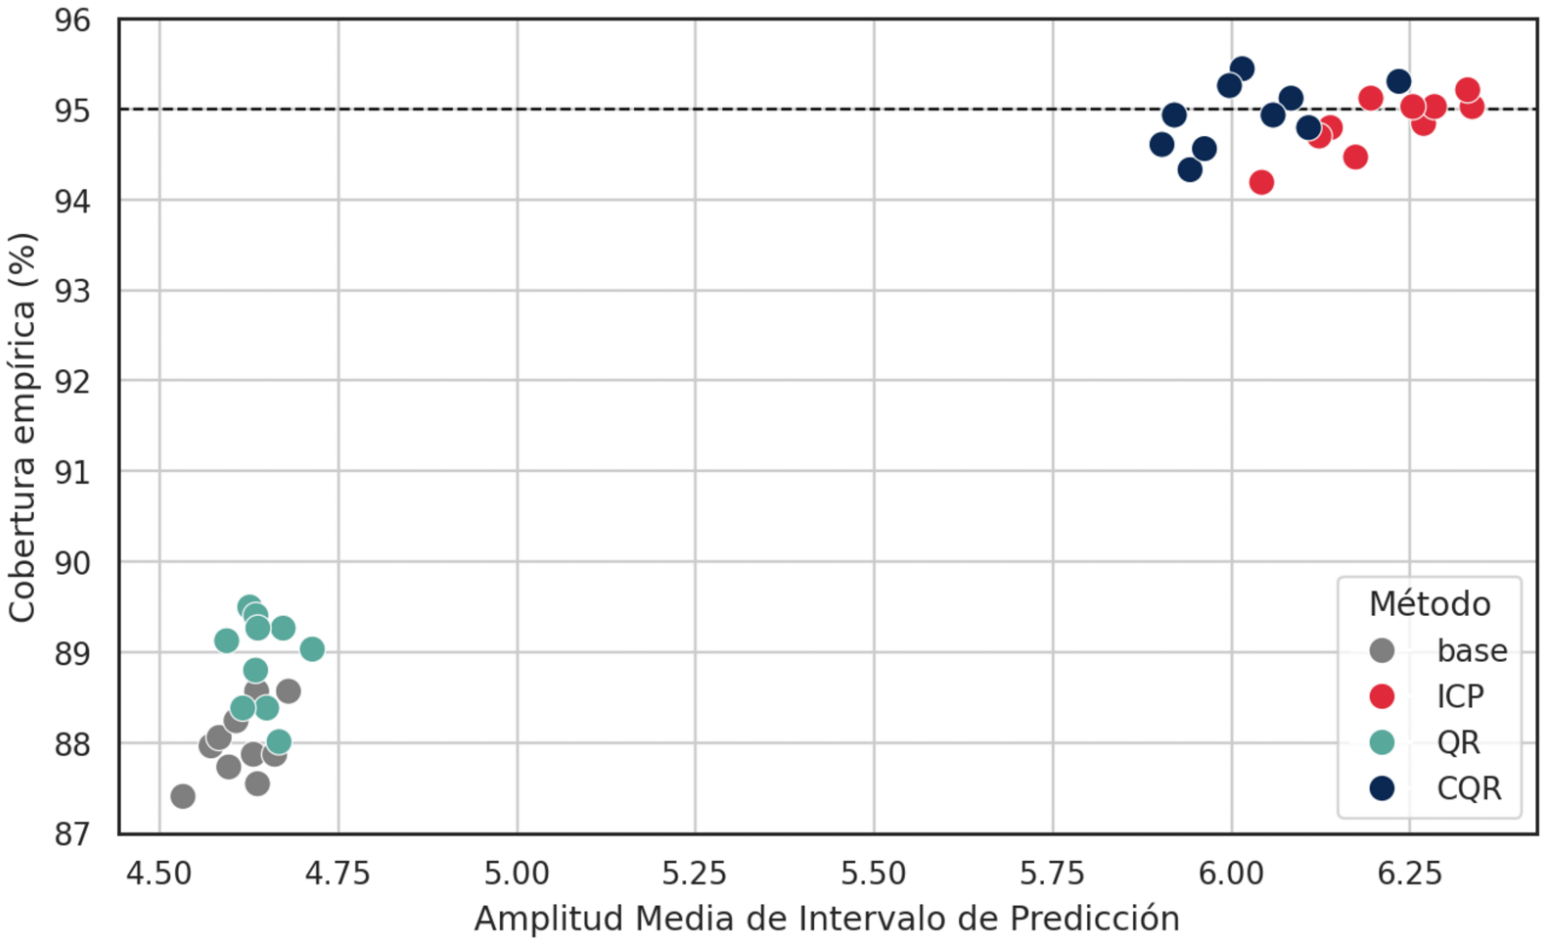

*

Resultados (III)

Cobertura en base a la amplitud del intervalo

- Los métodos ‘base’ e ICP siempre presentan los intervalos del mismo tamaño.
- CQR logra buenas coberturas tanto en los intervalos más estrechos como en los más amplios, pero empeora en intermedios.

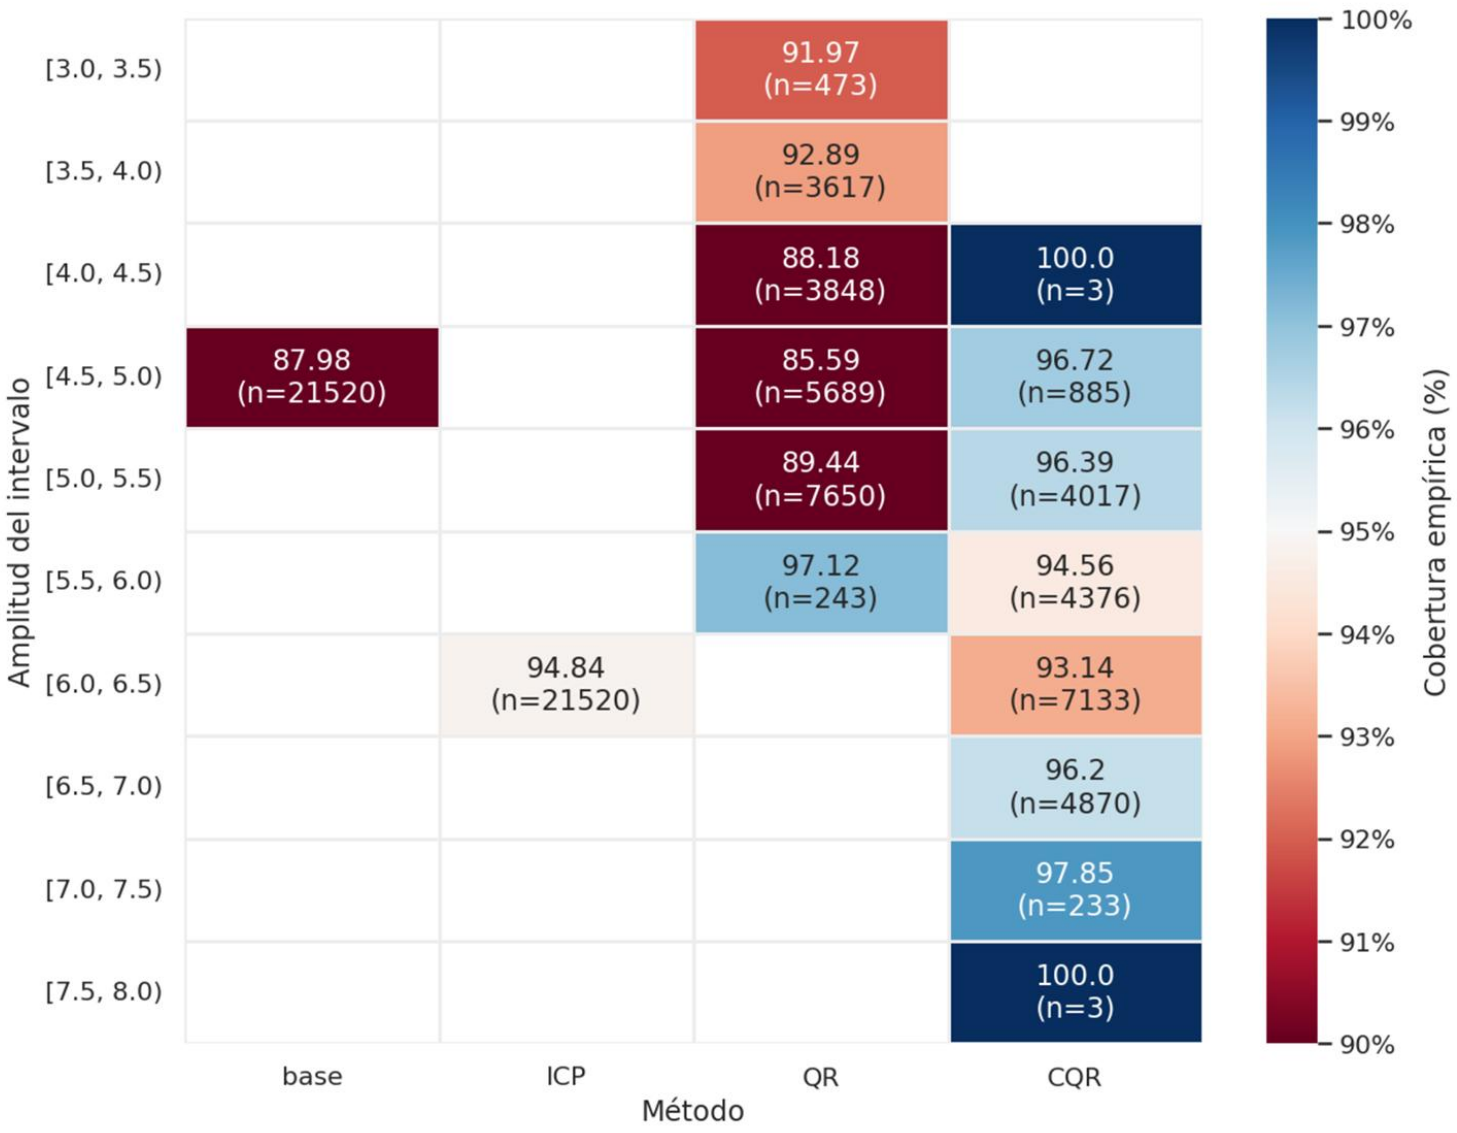

Resultados (IV)

Cobertura en base a la edad cronológica

- La cobertura decae a partir de los 22-23 años.
- CQR **presenta la cobertura más estable**, aumenta la amplitud de sus intervalos en edades avanzadas.
- ICP muestra su punto débil: todos sus intevalos presentan el mismo tamaño, y no se adapta a la incertidumbre en cada punto.

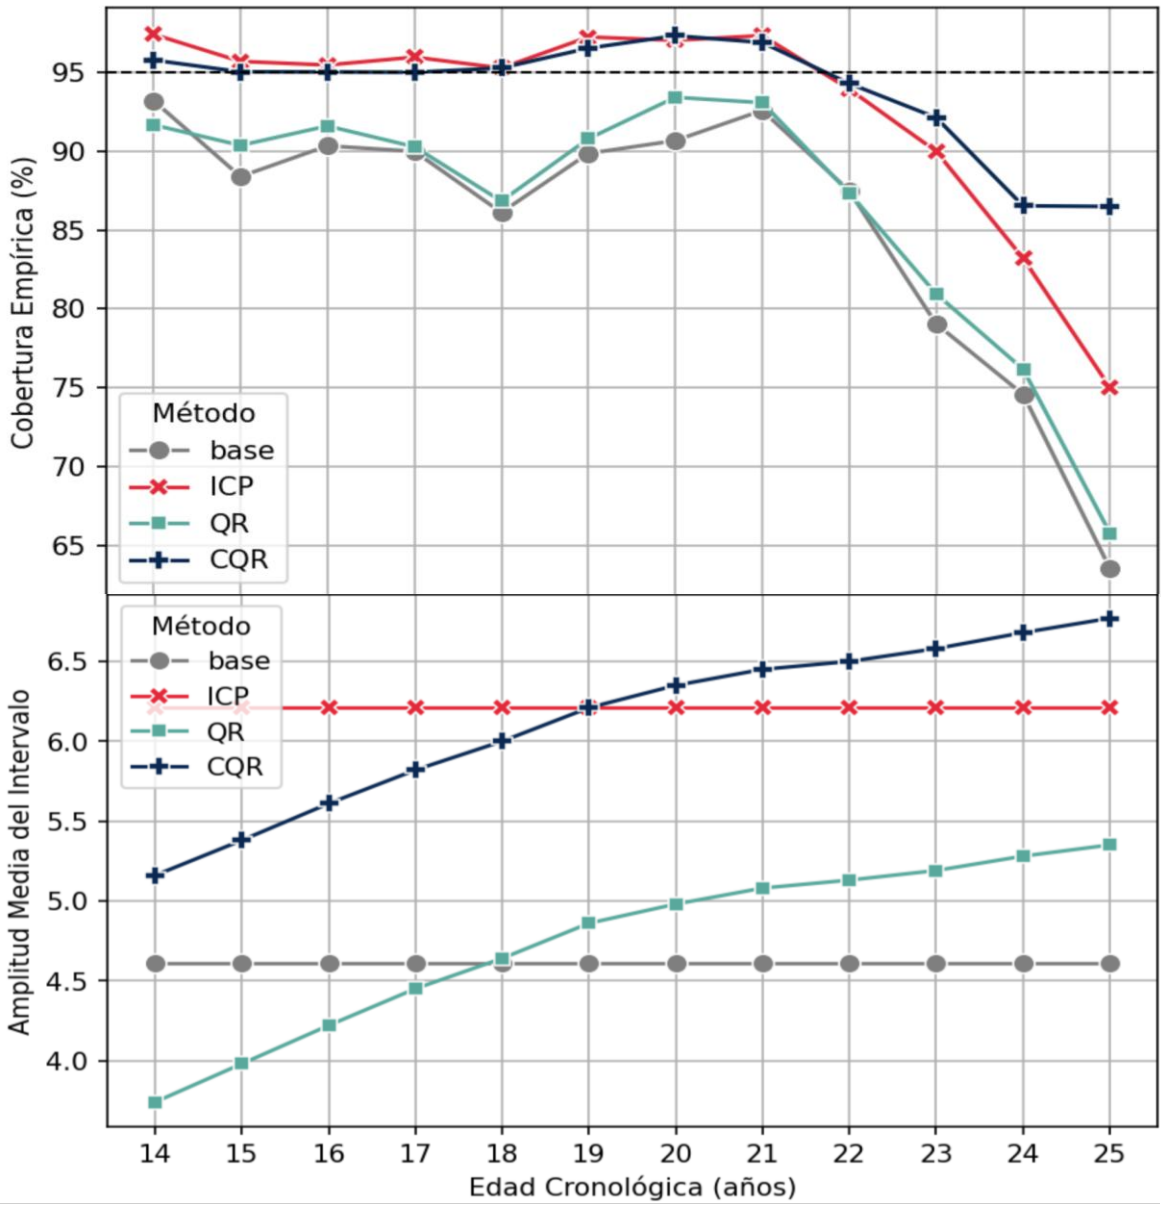

*

Conclusiones (I)

1 La predicción puntual y la interválica no están reñidas, **se complementan**.

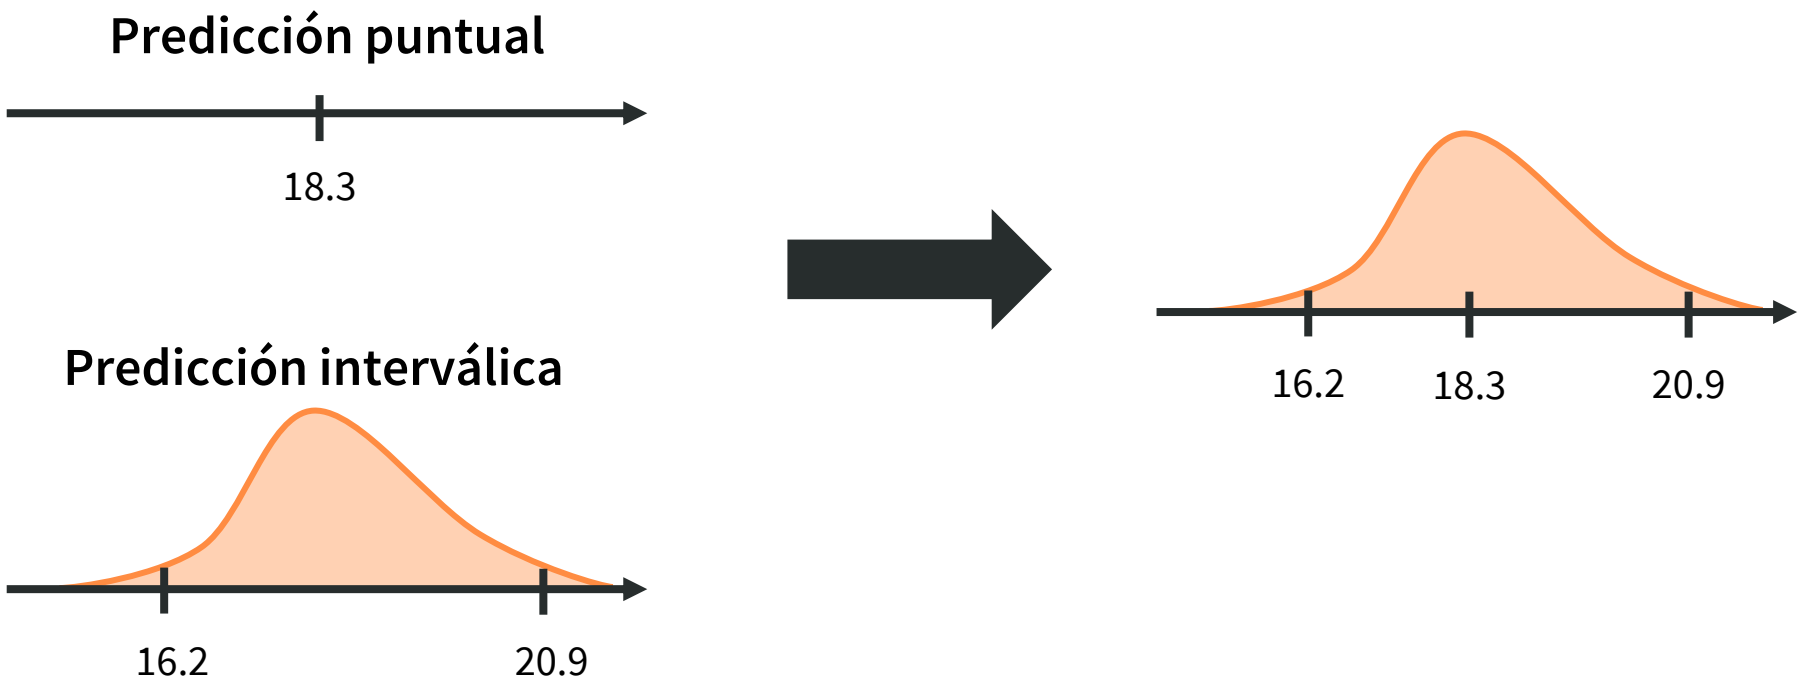

Conclusiones (II)

2 Los métodos de predicción conformal **no siempre alcanzan el nivel de cobertura deseado en todas las subpoblaciones**, pero existen diferencias entre métodos.

3 Los métodos adaptativos **permiten ajustar dinámicamente el tamaño del intervalo de predicción.**

4 A pesar de que requieren datos para calibración, la predicción conformal **apenas empeora los resultados de la predicción puntual**.

5 Al igual que la predicción puntual requiere de análisis del error, la predicción interválica **requiere una evaluación sistemática de la cobertura**.

Futuros trabajos

1 Integración con otros métodos de cuantificación de la incertidumbre

Por ejemplo, Conformalised Monte Carlo Dropout [1].

2 Aprovechamiento de información experta del dominio

Para realizar análisis de cobertura, teniendo en cuenta variables antropológicas avanzadas.

3 Combinación con técnicas de detección de datos *Out-of-Distribution* y de explicabilidad

Cubriendo debilidades de predicción conformal.

[1] Bethell, D., Gerasimou, S., & Calinescu, R. (2024, March). Robust uncertainty quantification using conformalised Monte Carlo prediction. In Proceedings of the AAAI Conference on Artificial Intelligence (Vol. 38, No. 19, pp. 20939-20948).

Gracias por su atención.

¿Alguna pregunta?

Extras

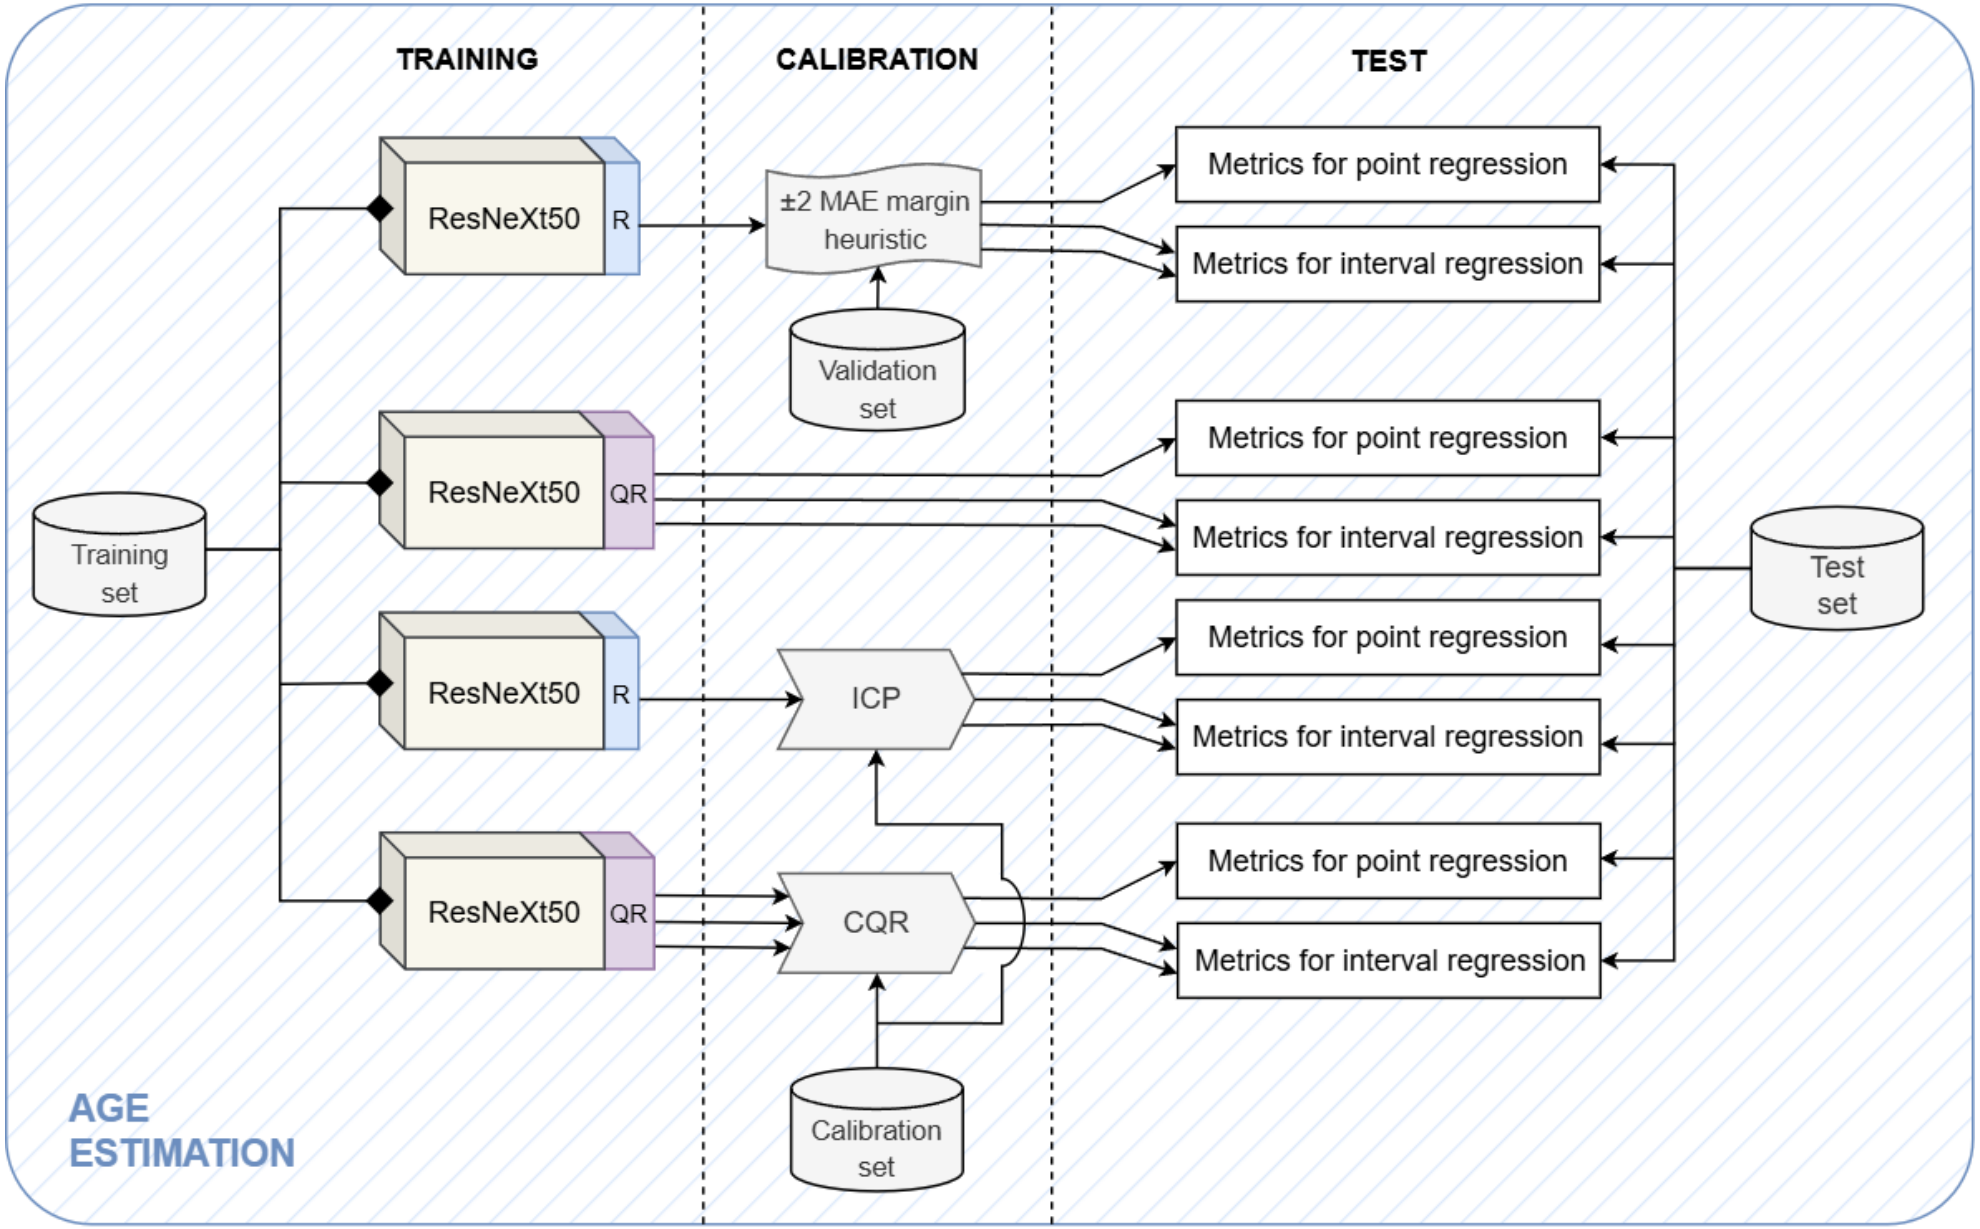
TRAINING
CALIBRATION
TEST
ResNeXt50
R
±2 MAE margin heuristic
Validation set
Metrics for point regression
Metrics for interval regression
ResNeXt50
QR
Metrics for point regression
Metrics for interval regression
Training set
Test set
ResNeXt50
R
ICP
Metrics for point regression
Metrics for interval regression
ResNeXt50
QR
CQR
Metrics for point regression
Metrics for interval regression
Calibration set
AGE ESTIMATION

Arquitectura escogida

ResNeXt50

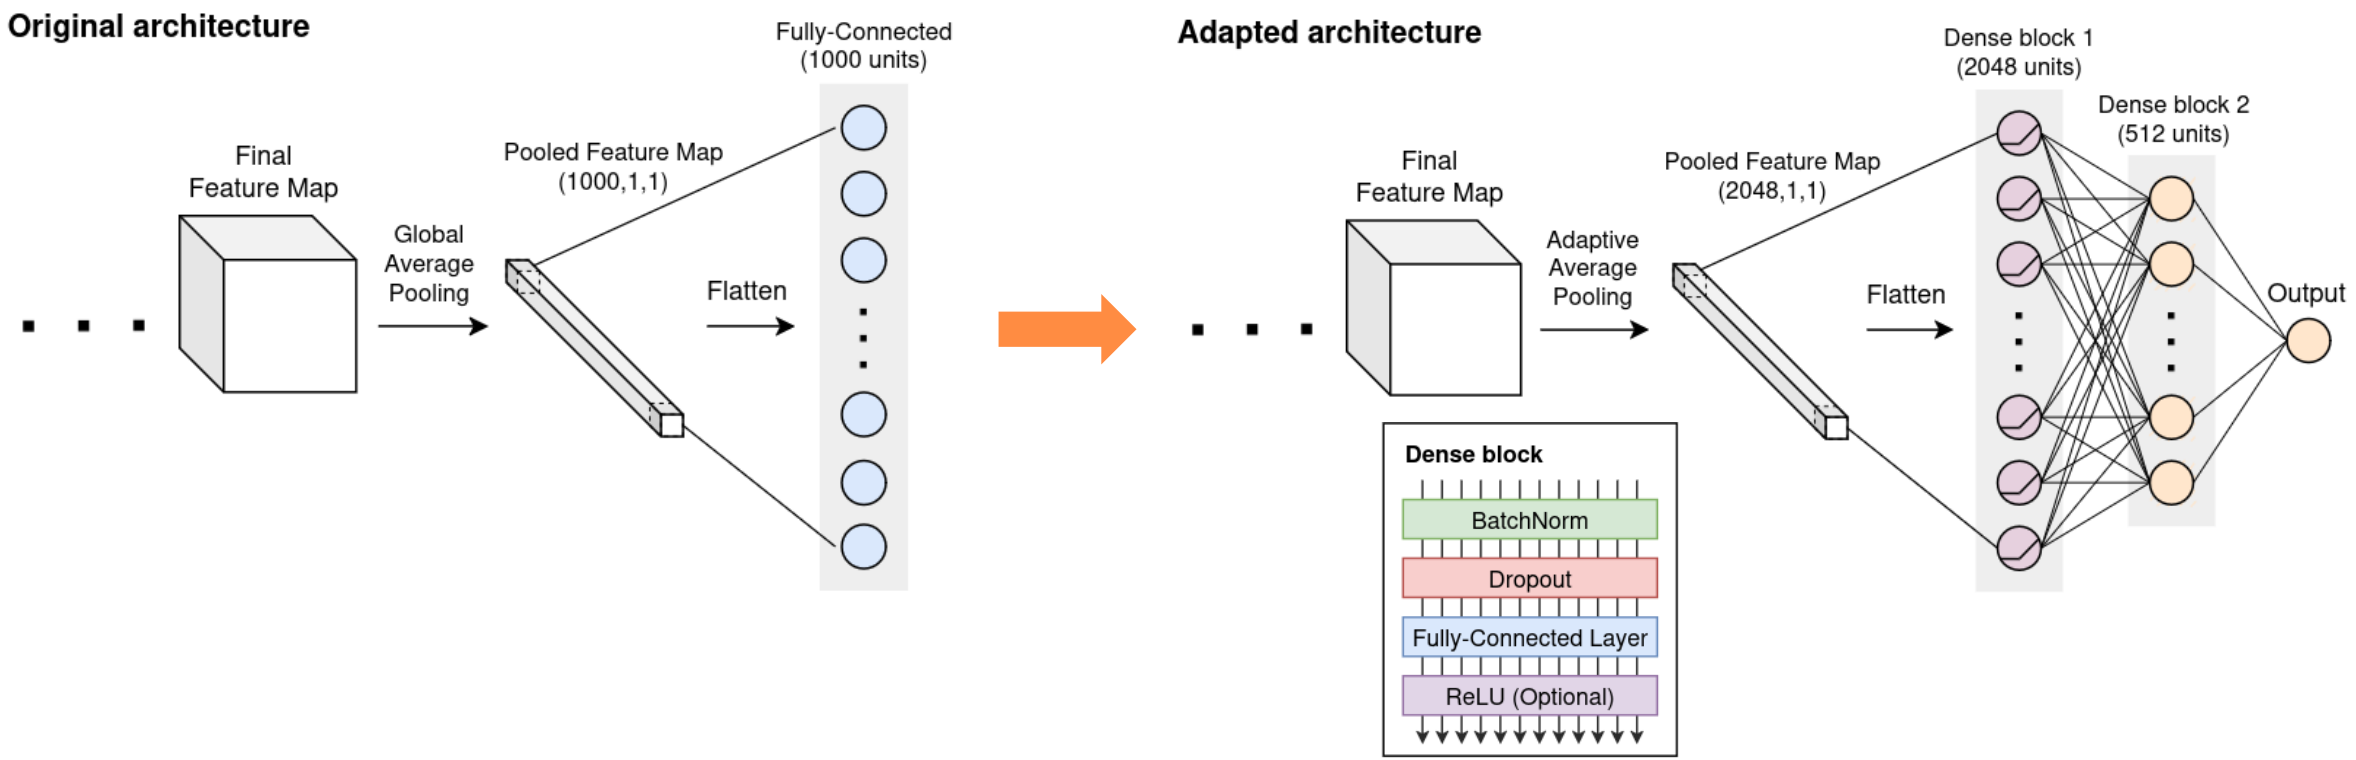

Resultados (IV)

Cobertura en base a la edad cronológica y el sexo
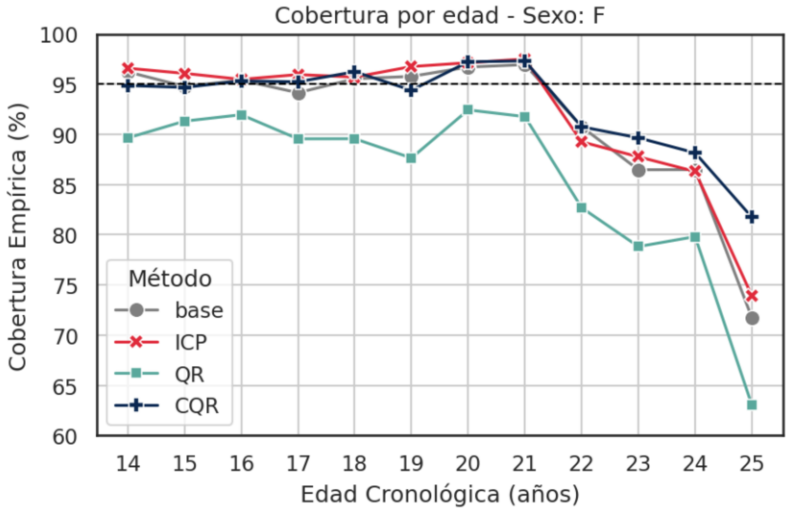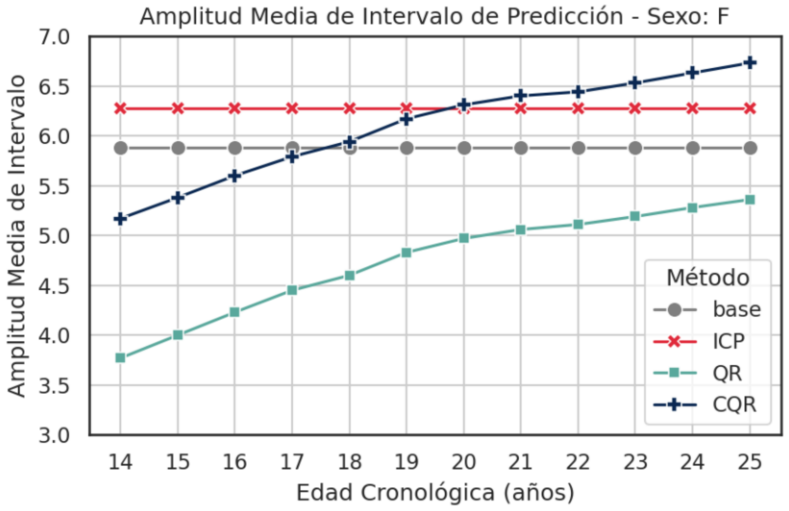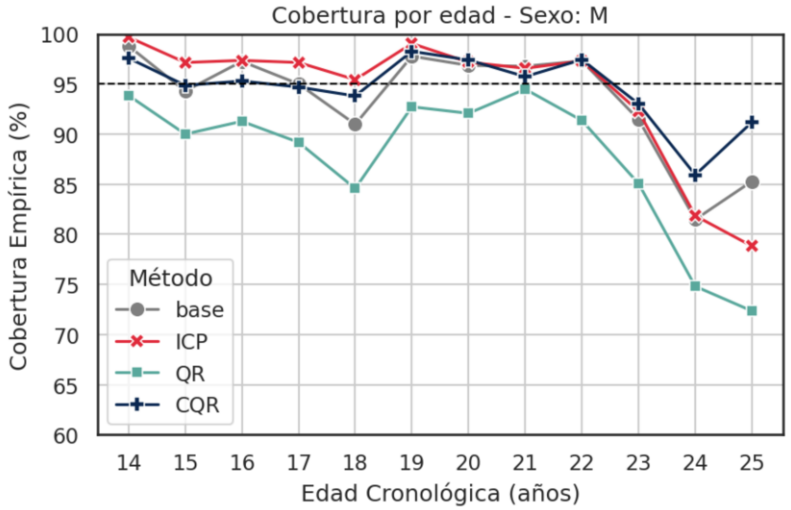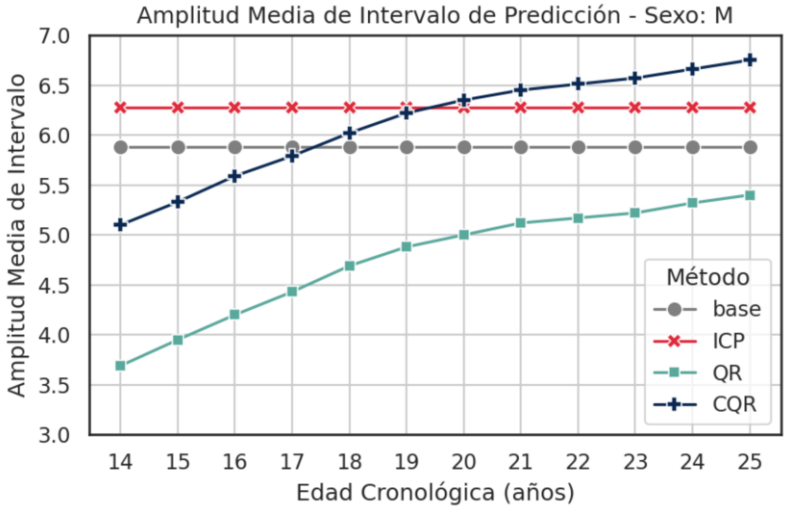
- La cobertura decae a partir de los 22-23 años.
- CQR es el que menos disminuye su tasa de cobertura, gracias a que aumenta la amplitud de sus intervalos en esas edades.
- La cobertura cae antes (22 años) y más acusadamente en mujeres que en hombres.
- ICP muestra su punto débil: todos sus intevalos presentan el mismo tamaño, y no se adapta a la incertidumbre en cada punto.